

这篇论文的内容主要介绍了一种**多源异构 特定辐射源 识别**（MH-SEI）方法展开讨论

首先，该论文方法的提出主要是用来解决如今**网络安全**的需求和目前对于**多元异构场景的射频信号识别方法的不足**。因此，提出一种多源异构特点辐射源识别的方法来解决多源异构射频信号的特定辐射源识别问题。

然后，该论文的创新点有三个

1. 提出 MH-SEI 方法：

为了充分利用现实场景中不同位置和类型的传感器，首次提出了多源异构特定辐射源识别方法，基于真实世界的多源异构射频信号，探索更适合实际场景的解决方案。

2. 设计 MHAFNN 网络：

提出了一种多源异构注意力指纹融合网络（MHAFNN），由多通道 RFF 特征提取模块、基于注意力机制的 RFF 融合模块和自动分类器组成，用于实现 MH-SEI 技术。

3. 构建实验环境验证：

构建了一个由一个发射器和三个不同接收器组成的多源异构实验环境，通过真实世界的信号数据验证了所提出的 MH-SEI 方法的有效性和优越性。

算法过程

系统模型由**数据收集模块**，**RFF 提取模块**，**RFF 融合模块**，**自动分类器模块**四个模块组成。

数据收集模块，主要是用于收集实验室中的多源异构射频信号。

RFF 提取模块，多分支并行结构，利用多分支多尺度 CNN，针对不同接收信号提取特征，包括卷积层、最大池化层和全连接层，从不同接收器的 I/Q 信号中提取射频指纹（RFF）。

RFF 融合模块，基于注意力机制，以模块化方式成对融合多个 RFF，通过计算注意力权重来分配不同 RFF 的重要性。突出重要特征，为自动分类器提供更有效的特征表示。

自动分类器模块，该模块三个全连接层，前两层用 ReLU 激活函数，最后一层用 Softmax 激活函数。以融合后的 RFF 为输入，对设备进行分类识别，输出识别结果。

实验结果

首先在可行性验证上，该方法在所有都有明显的优势，验证了其可行性。

然后在所模拟的不完美环境下，该方法在不同信噪比下都能更好的完成的特定辐射源识别任务，验证了其拥有更好的鲁棒性。

再通过模拟传感器破坏的场景，来验证了该方法具有更好的容错机制。

最后，分析 MHAFNN 的计算和存储开销，虽然相对复杂，但考虑到其性能优势，这种开销是可接受的。

一、多分支结构

1. **对应不同信号**：该模块有多个不同分支，对应多个异构的无线信号。在论文中设置了三个接收器，分别接收不同阶段的 LTE 通信信号，如原始射频信号、经过 CP-OFDM 解调后的信号以及经过信道均衡后的信号。
2. **分支处理流程**：每个分支以不同的接收数据（如 y_{Ri} ）开始，经过一些精心设计的网络层处理，最终输出该分支对应的射频指纹 RFF_{Ri} 。

二、多尺度 CNN 的体现

1. **适应不同信号结构长度**：考虑到不同接收信号（如 y_{R1} 、 y_{R2} 、 y_{R3} ）的结构长度不同，混合使用了一维卷积层和二维卷积层。
 - 例如，对于长度较长的信号可能更适合一维卷积层进行处理，而对于具有一定二维结构特征的信号可能采用二维卷积层能更好地提取特征。
2. **网络层组成及作用**：
 - **卷积层**：在每个卷积层后添加一个最大池化层，目的是压缩信号维度并进一步探索深度特征。卷积层的作用是提取不同层次的特征，不同的滤波器数量（如论文中的 Filter 值）和卷积核大小（如 Kernel 值）可以捕捉到不同尺度的信号特征。
 - **全连接层**：所有分支的最后一层设计为固定的全连接层，目的是为了获得相同长度的 RFF，以便后续输入到 RFF 融合模块进行处理。

综上所述，多分支多尺度 CNN 在 RFF 提取模块中能够有效地针对不同类型和结构的多源异构信号进行特征提取，为实现多源异构特定辐射源识别提供关键的射频指纹特征。

一、整体设计理念

该图展示了基于注意力机制设计的 RFF 融合模块，其目的是融合来自多个通道的 RFF，以解决多源异构特定辐射源识别 (MH-SEI) 问题中的特征融合需求。

二、各部分内容

1. 模块组成：

- 该模块以模块化方式设计，多个 RFF 将被成对融合。图中右侧展示了其中一个融合模块的扩展图。
- 融合模块的输入是来自不同通道的 RFF (如 Γ_{R1} 、 Γ_{R2} 、 Γ_{R3} 等)，输出是融合后的 RFF (Γ_{mix})。

2. 注意力机制的实现：

- 注意力权重计算：通过特定的计算方式得到注意力权重 ω_{ai} ，它是 RFF 融合算法计算得出的两个 RFF 之间的注意力权重。具体计算公式为 $\omega_a = \sigma [\cap (\Gamma_{R1} \oplus \Gamma_{R2}) \oplus \cup (\Gamma_{R1} \oplus \Gamma_{R2})]$ ，其中 σ 是 sigmoid 激活函数， $\cap(\cdot)$ 和 $\cup(\cdot)$ 分别对应图中的两个分支。
- 分支操作： $\cap(\cdot)$ 操作由卷积层和批归一化 (BN) 层组成； $\cup(\cdot)$ 比 $\cap(\cdot)$ 多了一个全局平均池化层。例如， $\cap(x) = \mathcal{L}_* \{ \delta_r \{ \mathcal{L}_{BN} [\mathcal{L}_* (x, \omega_*)] \}, \omega_* \}$ ， $\cup(x) = \mathcal{L}_* \{ \delta_r \{ \mathcal{L}_{BN} \{ \mathcal{L}_{*1} [\mathcal{L}_{GL}(x), \omega_*] \} \}, \omega_* \}$ ，其中 \mathcal{L}_* 、 \mathcal{L}_{BN} 、 \mathcal{L}_{GL} 分别表示卷积层、BN 层、全局平均池化层， ω_* 是对应的权重， δ_r 是 Relu 激活函数。

3. 融合过程：

- 根据注意力权重融合 RFF：融合后的 RFF Γ_{mix} 的计算公式为 $\Gamma_{mix} = \omega_{ai} \otimes \Gamma_{Ri} + (1 - \omega_{ai}) \otimes \Gamma_{R(i+1)}$ ，其中 \otimes 表示对应元素的乘法操作。在融合过程中，更重要的 RFF 将获得更高的权重，从而在融合后的 RFF 中发挥更重要甚至决定性的作用。

综上所述，图 4 展示了基于注意力机制的 RFF 融合模块如何通过计算注意力权重来融合多个通道的 RFF，为实现 MH-SEI 提供关键的特征融合功能。

一、整体结构

该图展示了自动分类器模块的结构，它由三个全连接层组成。

二、各部分内容

1. 输入与输出：

- 输入是融合后的射频指纹 (RFF)，经过自动分类器模块处理后，最终输出是设备识别的结果。

2. 全连接层及激活函数：

- 三个全连接层依次连接。前两个全连接层使用 Relu 激活函数，最后一层使用 Softmax 激活函数。
- 输出超参数由多源异构特定辐射源识别 (MH-SEI) 设备的类别数量决定，必须满足条件 $out = C_k$ 。

综上所述，图 5 清晰地展示了自动分类器模块如何利用三个全连接层对融合后的 RFF 进行处理，以实现针对不同设备的分类识别。

在深度学习中，“MaxPool”通常指最大池化（Max Pooling）操作。

一、定义与原理

最大池化是一种下采样（downsampling）方法，它在一个给定的窗口（通常是矩形区域）内，选取该区域中的最大值作为输出。例如，对于一个二维的图像特征图或信号矩阵，如果采用 2×2 的最大池化窗口，它会在 2×2 的区域内选择最大值作为这个区域的代表值。

二、作用

- 降低特征维度：**减少数据的空间尺寸，降低后续计算的复杂度和参数数量，从而提高计算效率，减少过拟合的风险。
- 提取主要特征：**通过选取局部区域内的最大值，能够突出特征图中的显著特征，抑制不显著的特征，有助于提取更具有代表性的特征信息，增强模型对重要特征的关注。
- 增强平移不变性：**一定程度上使模型对输入数据的微小平移具有鲁棒性，因为只要显著特征在局部区域内存在，无论其具体位置如何，最大池化都有较大概率提取到该特征。

在深度学习中，“Conv1D”指一维卷积（1D Convolution）操作。

一、定义与原理

- 一维卷积主要用于处理一维序列数据，比如时间序列数据、文本数据等。它通过一个滑动窗口在输入数据上进行操作，窗口内的权重与输入数据进行卷积运算得到输出值。
- 假设输入数据为一个一维序列 $x = \{x_1, x_2, \dots, x_n\}$ ，卷积核为 $w = \{w_1, w_2, \dots, w_k\}$ ，其中 n 表示输入序列长度， k 表示卷积核大小。在进行一维卷积时，对于位置 i 的输出 y_i 计算方式为：

$$y_i = \sum_{j=1}^k w_j \cdot x_{i+j-1}。$$

二、作用

- 特征提取：**能够自动学习输入数据中的局部模式和特征，通过不同的卷积核可以提取不同的特征，例如在时间序列数据中可以提取特定时间范围内的变化趋势等特征。
- 参数共享：**卷积核在整个输入序列上重复使用，大大减少了模型的参数数量，提高了计算效率，同时也使得模型能够学习到输入数据中的通用模式。
- 增强模型表达能力：**通过多个不同的卷积核进行特征提取，可以让模型学习到更加丰富的特征表示，从而提高模型对不同任务的适应能力。