

多域浅层特征引导下雷达有源干扰多模态对比识别方法

郭文杰^① 吴振华^{*①②} 曹宜策^{*①} 张 强^③ 张 磊^④ 杨利霞^①

^①(安徽大学电子信息工程学院 合肥 230601)

^②(中国电子科技集团公司第三十八研究所 合肥 230088)

^③(天基综合信息系统全国重点实验室 北京 100094)

^④(中山大学电子与通信工程学院 深圳 518107)

摘要: 在雷达有源干扰识别任务中,如何实现多域浅层特征与时频域深层网络特征的稳健联合,并在极端小样本下维持高干扰识别准确率是亟待解决的关键问题。针对此问题,该文提出一种多域浅层特征引导下雷达有源干扰多模态对比识别方法。在充分提取有源干扰多域浅层特征基础上,设计优选单元自动选择有效特征,生成对应含有隐式专家知识的文本模态。将文本模态与时频变换图像分别输入文本和图像编码器,构建多模态特征对并映射至模态对齐高维空间中,利用文本特征作为锚点,通过对比学习引导同类干扰的时频图像特征聚合,以优化图像编码器表征能力,实现干扰识别特征类内更聚集、类间更分离。实验结果表明,相较于已有深浅特征直接联合,所提引导式联合方法可以实现特征差异处理,从而提高识别特征判别力和泛化力。且在极端小样本条件(每类干扰训练样本为2~3个)下,所提识别方法较先进对比方法的准确率提升9.84%,证明了该文方法的有效性与鲁棒性。

关键词: 雷达有源干扰识别; 极端小样本; 多域浅层干扰特征; 多模态; 监督对比学习

中图分类号: TN958

文献标识码: A

文章编号: 2095-283X(2024)x-0001-15

DOI: 10.12000/JR24129

引用格式: 郭文杰, 吴振华, 曹宜策, 等. 多域浅层特征引导下雷达有源干扰多模态对比识别方法[J]. 雷达学报(中英文), 待出版. doi: 10.12000/JR24129.

Reference format: GUO Wenjie, WU Zhenhua, CAO Yice, et al. Multidomain characteristic-guided multimodal contrastive recognition method for active radar jamming[J]. *Journal of Radars*, in press. doi: 10.12000/JR24129.

Multidomain Characteristic-guided Multimodal Contrastive Recognition Method for Active Radar Jamming

GUO Wenjie^① WU Zhenhua^{*①②} CAO Yice^{*①} ZHANG Qiang^③
ZHANG Lei^④ YANG Lixia^①

^①(School of Electronic and Information Engineering, Anhui University, Hefei 230601, China)

^②(The 38th Research Institute of China Electronics Technology Group Corporation, Hefei 230088, China)

^③(National Key Laboratory of Space Integrated Information System, Beijing 100094, China)

^④(School of Electronics and Communication Engineering, Sun Yat-sen University, Shenzhen 518107, China)

Abstract: Achieving robust joint utilization of multidomain characteristics and deep-network features while maintaining a high jamming-recognition accuracy with limited samples is challenging. To address this issue, this

收稿日期: 2024-06-21; 改回日期: 2024-08-12; 网络出版: 2024-xx-xx

*通信作者: 吴振华 zhuwu@ahu.edu.cn; 曹宜策 yccao@ahu.edu.cn

*Corresponding Authors: WU Zhenhua, zhuwu@ahu.edu.cn; CAO Yice, yccao@ahu.edu.cn

基金项目: 国家自然科学基金(62201007), 中国博士后科学基金(2020M681992), 安徽省自然科学基金(2308085QF199)

Foundation Items: The National Natural Science Foundation of China (62201007), The China Postdoctoral Science Foundation (2020M681992), Anhui Provincial Natural Science Foundation (2308085QF199)

责任编辑: 刘振 Corresponding Editor: LIU Zhen

paper proposes a multidomain characteristic-guided multimodal contrastive recognition method for active radar jamming. This method involves first thoroughly extracting the multidomain characteristics of active jamming and then designing an optimization unit to automatically select effective characteristics and generate a text modality imbued with implicit expert knowledge. The text modality and involved time-frequency transformation image are separately fed into text and image encoders to construct multimodal-feature pairs and map them to a high-dimensional space for modal alignment. The text features are used as anchors and a guide to time-frequency image features for aggregation around the anchors through contrastive learning, optimizing the image encoder's representation capability, achieving tight intraclass and separated interclass distributions of active jamming. Experiments show that compared to existing methods, which involve directly combining multidomain characteristics and deep-network features, the proposed guided-joint method can achieve differential feature processing, thereby enhancing the discriminative and generalization capabilities of recognition features. Moreover, under extremely small-sample conditions (2~3 training samples for each type of jamming), the accuracy of our method is 9.84% higher than those of comparative methods, proving the effectiveness and robustness of the proposed method.

Key words: Radar active jamming recognition; Extreme small samples; Multidomain jamming characteristics; Multimodal; Supervised contrastive learning

1 引言

现代雷达作战面临日趋复杂的电磁干扰环境，快速、准确地辨识有源干扰类型是雷达认知干扰对抗的先决条件，对后续针对性实施干扰抑制措施^[1]与交互学习生成最优干扰对抗策略^[2]至关重要。传统干扰识别流程通常是对回波的时域、频域、变换域中的关键特征参数进行提取，如时域矩峰度、峰均值功率比、快速脉内调制系数等，以实现欺骗类、调制噪声压制类、时域起伏压制类有源干扰的初步辨识。接着，通过深入分析双谱域、脉压域、时频域等调制域中的特性，提取如包络起伏、瞬时幅频最大值、频域峰均值功率比、频率平稳度等关键差异特征参数，进一步对有源干扰中的假目标欺骗类和时域起伏压制类进行精细辨识。基于人工设计提取的多域浅层特征与决策树、支持向量机等分类器相结合的有源干扰流式识别方法^[3]，在单一参数下多干扰类型分类上较为有效，但该类方法强依赖专家经验进行特征降维与稳健特征筛选，难以应对当前越来越复杂的复合干扰。

借助深度神经网络对图像域深层特征高效学习与提取能力，特别是以卷积神经网络(Convolutional Neural Networks, CNN)为代表的深度网络，对多域干扰特征图像模态，包括时频图^[4]、双谱图^[5]、功率谱图^[6]进行监督训练学习，已被广泛应用于有源干扰识别领域中。近年来，为适应快变动态干扰对抗作战环境，小样本条件下的深度学习稳健干扰识别方法成为研究热点。欺骗类有源干扰经时频变换后，虽在时频域中展现出明显条纹分布特性，但同时也兼具较高相似性。这使得在有源干扰深度学

习识别模型训练中，特别是面临类间、类内具有一定相似性小样本条件时，模型容易陷入过拟合，并且泛化能力受到严重挑战。针对此问题，数据增广^[7]、迁移学习^[8]、集成学习^[9]、知识蒸馏^[10]，对比学习^[11]等小样本条件下基于单一时频变换域有源干扰深度学习识别方法相继被提出。此外，为充分挖掘单模时频谱图深层网络特征，文献[12]引入慢时间距离-多普勒图与快时间时频谱图进行联合特征学习。文献[13]则联合分数阶傅里叶变换时频图与短时傅里叶变换(Short Time Fourier Transform, STFT)时频图实现局部和全局特征融合。

除了深入探索时频图像的深层网络特征外，已有研究还成功地将传统特征整合到深度学习框架中。这些研究通过联合多域浅层特征与深层网络特征，使得干扰识别特征在保持深层语义表征能力的同时，融入了物理特性，从而实现了对干扰类型更全面且精确的描述。文献[14]通过构建基于一维卷积神经网络(One Dimensional Convolutional Neural Network, 1D-CNN)和长短期记忆网络的双通道拼接网络，有效融合了欺骗干扰的快-慢时间维图像特征和幅频响应特征，显著提升了识别性能。文献[15]讨论了多模态特征融合算法，该算法通过卷积层和池化层将干扰的时域特征、信息统计特征和时频域图像特征向量进行有效融合。文献[16]采用原型网络提取干扰的多域浅层特征和时频图像的深层特征，通过拼接特征向量并应用迁移学习技术，显著提高了识别性能和泛化能力。文献[17]则是利用1D-CNN和二维卷积神经网络(Two Dimensional Convolutional Neural Network, 2D-CNN)分别提取干扰的时域特征和时频图像特征，

并通过特征向量拼接实现了信息的有效整合。此外, 其他领域的研究者也积极探索了浅层与深层特征联合的方法。文献[18]利用基于注意力的互反特征融合机制, 将散射点的拓扑信息纳入了网络学习合成孔径雷达(Synthetic Aperture Radar, SAR)图像特征的过程, 提高了小样本船舶SAR图像分类的精度和鲁棒性。文献[19]通过基于交叉注意力的散射与空间信息交互模块, 在散射感知特征和极化SAR图像斑块空间特征之间建立信息交换, 缓解了两类特征语义信息的不平衡, 使聚合后的特征更具辨别性, 进而增强了对土地覆盖分类特征的辨别能力。文献[20]分析了在输入数据维度拼接、中间隐层特征拼接、输出识别概率加权3种不同的特征融合方式后, 通过前级特征交互模块和深层注意力特征融合模块, 实现了回波特征和目标方位角度在特征提取各个阶段的层次化融合。文献[21]分别提取海杂波和目标信号的幅值特征和时间-多普勒域图像特征, 使用基于CNN的双通道网络提取特征, 并通过全连接层实现双通道特征融合。

虽然多域浅层特征与深层网络特征的联合应用在雷达智能干扰识别领域取得了一定进展, 但当前研究仍面临诸多挑战。首先, 浅层物理特征与深层抽象特征间在属性和表征力上存在本质差异, 这就要求在联合这些特征时需采取更加精细的策略。直接进行简单的特征联合, 有可能加重后端网络优化的复杂度, 甚至可能因特征属性的显著差异而抑制浅层物理特征对提高干扰特征识别力的正向促进效果。其次, 现有联合策略通常只侧重于追求浅层特征的多样性, 而缺乏对特征的冗余性和任务适应性的考量。

针对上述挑战, 有必要探索更加稳健有效的有源干扰多域浅层特征与时频域深层网络特征联合策略, 能够充分利用浅层物理特征与深层抽象特征各自的优点, 以提升在极端小样本下干扰识别模型的鲁棒性和可靠准确性。针对前述有源干扰多域浅层特征与时频域深层网络特征的稳健联合挑战, 以及如何维持极端小样本条件(每类干扰训练样本为2~3个)下高干扰识别准确率的问题, 基于多模态对比学习框架^[22], 本文提出了一种多域浅层特征引导下雷达有源干扰多模态对比识别方法。在充分提取有源干扰多域浅层特征基础上, 设计优选单元自动选择有效特征, 生成对应含有隐式专家知识的文本模态。将文本模态与时频变换图像分别输入至文本与图像编码器, 构建多模态特征对并映射至模态对齐高维空间中, 利用文本特征作为锚点, 通过对比学习引导时频特征向锚点聚合, 以优化图像编码

器表征能力, 实现有源干扰类内更加聚集、类间更加分离。实验结果表明, 相较于已有深浅特征直接联合策略, 本文所提出的引导式联合方法能够有效处理特征差异, 从而提高识别特征判别力和泛化力。

2 雷达干扰数据及多域浅层特征

2.1 雷达有源干扰数据集

本文在深入分析少量实测干扰数据的基础上, 对针对线性调频雷达发射信号的多种有源干扰作用机理充分认知, 以及多类型干扰关键参数进行了建模分析, 对应生成了基于实测数据的包含经典单一与复合样式的有源干扰数据集。

通常情况下, 以脉冲多普勒雷达发射的线性调频(Linear Frequency Modulation, LFM)信号作为雷达发射信号 $s(t)$, 表达式如下:

$$s(t) = \text{rect}\left(\frac{t}{T}\right) \exp(i\pi kt^2) \quad (1)$$

其中, $\text{rect}(\cdot)$ 为矩形窗函数; T 为脉宽; k 为雷达发射信号调频斜率, $k = B/T$, B 为带宽; $i = \sqrt{-1}$ 。

雷达接收机的接收信号 $r(t)$ 一般为雷达发射信号 $s(t)$ 、干扰信号 $J(t)$ 和高斯白噪声 $n(t)$ 的叠加, 表示为

$$r(t) = s(t) + J(t) + n(t) \quad (2)$$

雷达有源干扰识别任务针对式(2)所示接收信号进行识别。为验证所提干扰识别算法的广泛适用性, 本文在构建的数据集中共包含了8种典型的单一有源干扰样式, 具体为噪声卷积干扰(Noise Convolution Jamming, NCJ)和灵巧噪声干扰(Smart Noise Jamming, SNJ)2种压制干扰, 以及梳状谱干扰(COMB Jamming, COMBJ)、频谱弥散干扰(Smeared Spectrum Janning, SMSPJ)、相参压制干扰(Coherent Suppressing Jamming, CSJ)^[23]、密集假目标干扰(Dense False Target Jamming, DFTJ)、间歇采样循环转发干扰(Interrupted Sampling and Cyclic repeater Jamming, ISCJ)和调制间歇采样重复转发干扰(Modulated Interrupted Sampling and Repeater Jamming, MISRJ)^[24]6种欺骗干扰。

另外, 在复杂的电磁对抗环境中, 雷达系统为确保作战效能, 往往会遭遇多源干扰设备的协同攻击。因此, 雷达接收机面临的挑战不仅限于单一干扰源, 还需应对由两个或更多独立干扰源组成的复合干扰。为验证所提算法在识别复合干扰方面的精准性, 本文构建的数据集还涵盖了多种复合有源干扰样式。且重点聚焦在由压制性干扰与欺骗性干扰以及欺骗性干扰之间的加性复合干扰, 以确保复合

干扰效应的合理性和有效性。具体而言, 所构建的数据集包括了噪声卷积与密集假目标复合干扰(NCJ+DFTJ)、灵巧噪声干扰与密集假目标复合干扰(SNJ+DFTJ)、梳状谱与间歇采样循环转发复合干扰(COMBJ+ISCJ)、相参压制与频谱弥散复合干扰(CSJ+SMSPJ)、调制间歇采样重复转发与间歇采样循环转发复合干扰(MISRJ+ISCJ)和调制间歇采样重复转发与频谱弥散复合干扰(MISRJ+SMSPJ)共6种加性复合干扰。

本文构建的雷达有源干扰数据集的时频图像如图1所示。基于这一数据集, 对提出的方法以及先进的对比方法开展了丰富的实验验证工作, 旨在全面评估所提方法在单一与复合干扰共存的复杂电磁环境场景下的干扰识别性能。

2.2 干扰多域浅层特征

本文提出的干扰识别方法将多域浅层特征转化为文本模态, 以支持后续多域浅层特征引导策略的实现。为此, 基于干扰的一维数据, 本文从时域、频域、时频域、双谱域、小波域和统计域共6个调制域提取干扰的多域浅层特征, 表1展示了这些特征的中英文名称。在时域中, 我们主要关注时域矩偏度、时域矩峰度、包络起伏度和快速脉内调制识别参数, 以捕捉干扰在时间维度的变化特性。频域分析则侧重于频域矩偏度、频域矩峰度、载波因子和高斯白噪声因子, 以揭示干扰的频率特性。时频

域特征, 包括时频图像的重心和标准差, 描述了信号在时频平面上的分布特性, 有助于识别干扰时频变化。双谱域通过分析双谱方差和双谱矩阵特征, 展现了信号的高阶统计特性, 对复杂干扰识别至关重要。小波域关注信号的方差、均值、最大值、尺度重心、最大奇异值和中心矩, 以揭示小波变换后干扰的局部细节和整体特性。统计域则通过信息熵、指数熵和范数熵参数, 衡量干扰的不确定性和复杂性, 有效区分具有不同统计特性的干扰。通过综合这些来自不同调制域的浅层特征, 以更全面地描述干扰信号的特性, 为后续的干扰识别提供更为准确和丰富的信息。

3 多域浅层特征引导下雷达有源干扰多模态对比识别方法

图2展示了本文提出的多域浅层特征引导下雷达有源干扰多模态对比识别方法的具体流程, 主要包含训练阶段和测试阶段。在训练阶段, 所提出的多域浅层特征引导的雷达有源干扰多模态对比网络, 以干扰时域信号作为输入, 分别进行多域浅层特征的嵌入和时频图像深层特征的提取, 以获得多域文本特征和时频图像特征。随后, 将文本和图像特征映射到模态对齐高维空间中, 实现多模态特征的对齐, 进而实现雷达有源干扰精确识别。具体来说, 首先通过STFT, 生成第*i*个干扰相应的二维时频图像, 并在时频图像深层特征提取模块利用图像

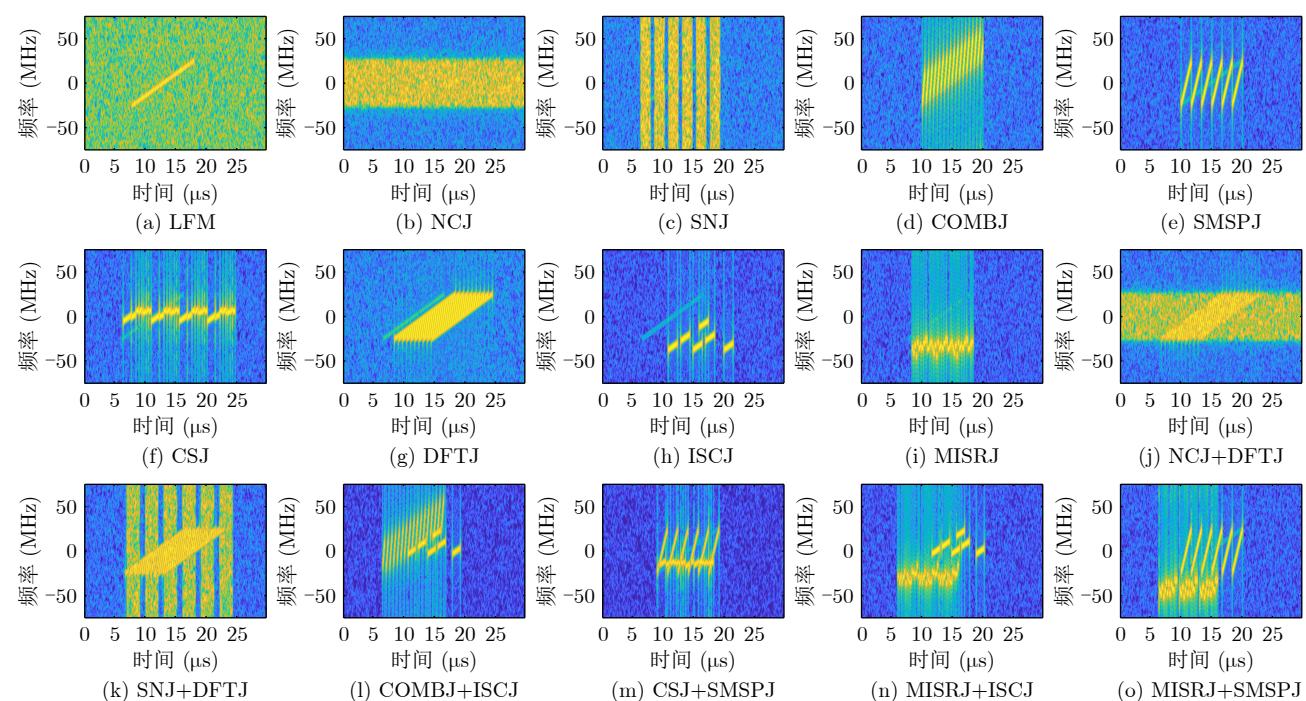


图1 雷达发射信号与雷达干扰的时频图像

Fig. 1 Time-frequency spectrograms of the target signal and radar jamming

表 1 雷达干扰多域浅层特征

Tab. 1 Multidomain characteristics of radar jamming

调制域	干扰特征中英文名称
时域	矩偏度 Time domain skewness 矩峰度 Time domain kurtosis 包络起伏度 Envelope undulation 快速脉冲内调制识别参数 Fast intra pulse modulation recognition parameters
频域	矩偏度 Frequency domain skewness 矩峰度 Frequency domain kurtosis 载波因子 Carrier factor 加性高斯白噪声因子 Additive Gaussian white noise factor
时频域	时频图像重心 Centroid of time-frequency image 时频图像标准差 Time frequency image standard deviation
双谱域	双谱方差 Bispectral variance 双谱均值 Bispectral mean
小波域	方差 Variance 均值 Mean value 最大值 Maximum 尺度重心 Scale center of gravity 最大奇异值 Maximum singular value 中心矩特征 Central moment feature
统计域	信息熵 Information entropy 指数熵 Exponential entropy 范数熵 Norm entropy

编码器提取其图像特征 p_i 。同时，在多域浅层特征嵌入模块，获得第*i*个干扰的多域浅层特征，通过设计的多域特征优选单元自动选择特征，并生成相应的文本模态信息。之后，使用文本编码器将这些文本转换为包含专家知识的多域文本特征 t_i 。最后，在多模态特征对齐模块，将时频图像特征 p_i 和多域文本特征 t_i 作为多模态特征对，映射至模态对齐高维空间中，并将文本模态特征作为锚点，通过对比学习引导时频图像特征 p_i 在类内更聚集，在类间更分离，以优化图像编码器表征能力。随后，利用调整后的时频图像特征 p_i 判别干扰类型。在测试阶段，直接利用训练完全的图像编码器和分类器来精确识别雷达有源干扰的类型。

3.1 时频图像深层特征提取

干扰信号的二维时频图像能够直观地展示干扰信号在时间和频率两个维度上的变化，从而提供丰富的干扰信息。因此，本文使用时频图像深层特征提取模块来提取干扰信号的时频图像特征，进而获得不同干扰类型的图像模态信息。如图2所示，该模块主要由图像编码器和分类器构成。首先，对干扰信号进行数据预处理。STFT作为经典的时频分析方法，在雷达信号处理中因直观易懂、计算效率高以及平衡的时间和频率分辨率等优点而被广泛使用。因此，我们采用STFT将一维干扰信号转换为二维时频图像。之后，将时频图像输入到图像编码器中，提取图像特征。图像编码器是基于轻量级网络EfficientNetV2^[25]构建的，其详细网络参数见表2。其中，Fused-MBConv (Fused-Mobile inverted Bottleneck Convolution)层通过同时调整深度和宽度来提高模型效率；MBConv (Mobile inverted Bottleneck Convolution)层利用可分离卷积来降低计算复杂度；池化(Pooling)层用于降低特征的空间维度，同时增加对图像位移的不变性；全连接(Full Connect, FC)层用于整合特征并为分类器提供输入。接着，将图像编码器提取的时频图像深层特征输入分类器，以获得相应的干扰预测概率。分类器主要由全局最大池化层和全连接层构成。其中，全连接层的输出维度对应干扰数据集中的干扰类别总数。最后，计算预测概率输出与真实标签的独热(one-hot)编码之间的交叉熵损失，得到分类损失 L_{cls} ，该损失衡量了模型预测与实际标签之间的差异：

$$L_{cls} = -\frac{1}{N} \sum_i \sum_c \mathbf{y}_i^c \ln(\mathbf{p}_i^c) \quad (3)$$

其中， \mathbf{p}_i 表示第*i*个干扰样本的预测概率，而 \mathbf{y}_i 是相应的真实标签，*c*为干扰类别总数，*N*为训练样本的个数。

在训练过程中，图像编码器中加载了使用大规模数据集ImageNet-1K预训练得到的权重，通过预训练权重中蕴含的知识，以减轻极端小样本情况下图像编码器过拟合的问题，帮助其维持泛化能力。同时，我们冻结了图像编码器的0~4阶段，如表2所示，仅对5~7阶段进行训练，以微调图像编码器，使其更好地适应本文中使用的干扰时频图像。

3.2 多域浅层特征嵌入

面对日益多样化的干扰类型，尤其是在包含单一和复合干扰的复杂电磁对抗场景中，基于单一图像模态的识别方法显示出了局限性。这些方法通常难以全面捕捉干扰信号的特性，特别是在极端小样

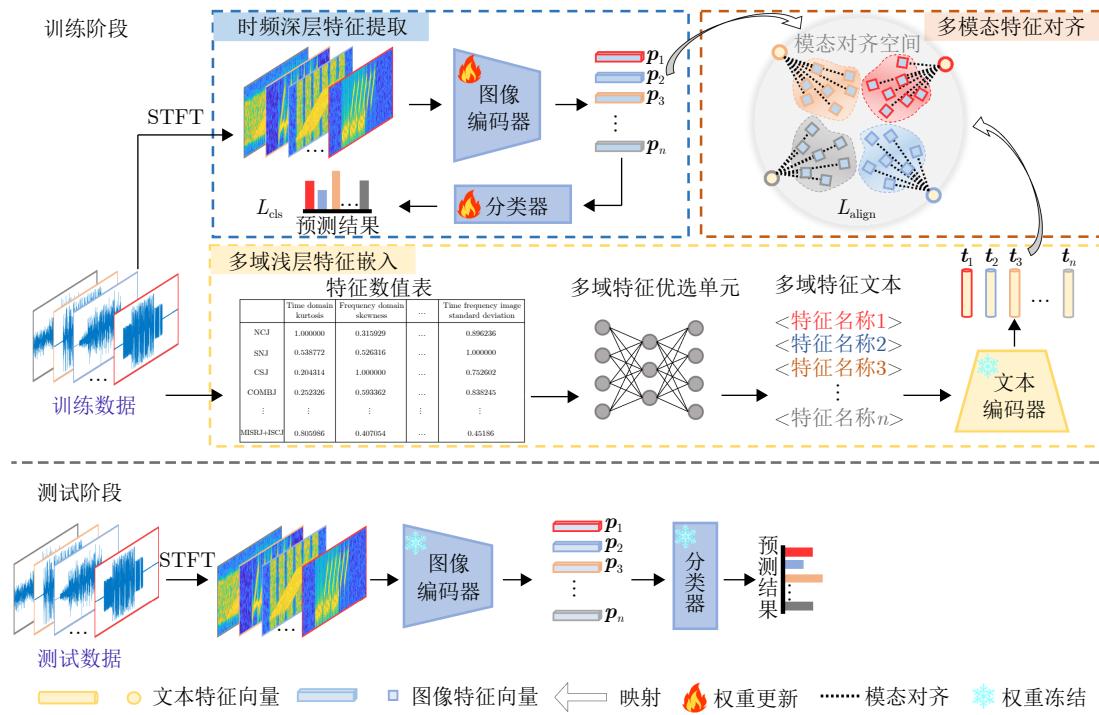


图2 所提方法的算法流程图

Fig. 2 Algorithm flowchart of the proposed method

表2 EfficientNetV2网络结构
Tab. 2 EfficientNetV2 architecture

阶段	名称	通道数	层数	状态
0	Conv	24	1	冻结
1	Fused-MBConv	24	2	冻结
2	Fused-MBConv	48	4	冻结
3	Fused-MBConv	64	4	冻结
4	MBConv	128	6	冻结
5	MBConv	160	9	训练
6	MBConv	272	15	训练
7	Conv & Pooling & FC	1792	1	训练

本条件下,训练数据的不足使得模型无法学习到具有强辨别性的特征,进而导致识别精度显著下降。具体来说,虽然时频图像能直观展示信号在时间和频率上的分布,但其在复杂情况下对干扰的表征存在不足。尤其是复合干扰,其时频图像可能包含多个重叠或相互干扰的单一干扰特征,这使得仅依赖图像模态的识别变得特别困难。为了解决这一问题,我们设计了多域浅层特征嵌入模块,如图2所示,引入文本模态来丰富模型学习的信息,从而提高极端小样本情况下模型的干扰识别精度。首先,本文设计的多域特征优选单元能自动将筛选后的多域浅层特征转换为包含隐式专家知识的文本。随后,这些文本通过文本编码器进一步提取为文本特征,并在后续对齐模块中引导时频图像深层特征进

行调整。多域浅层特征嵌入模块能自动筛选出具有代表性的特征,取代了传统方法中依赖专家知识指导的特征选择。此外,多域浅层特征的嵌入将专家知识隐含于特征选择和文本生成的过程中。这不仅提高了识别模型的泛化能力,还优化了其在不同干扰场景下的识别性能。

多域浅层特征嵌入模块主要由设计的多域特征优选单元和文本编码器组成。为了减小多域浅层特征中可能存在的无用或噪声特征对后续识别造成的负面影响,获得更准确、有效的干扰识别结果,我们设计了多域特征优选单元,对提取的多域浅层特征进行筛选,并将优选特征的名称作为文本模态信息,组成多域特征文本,输入文本编码器。

多域特征优选单元算法流程示意图如图3所示(关键步骤的详细处理以NCJ为例)。这一过程受自然语言处理领域表格到文本(Table2Text)任务^[26,27]的启发。首先,提取干扰的多域浅层特征,如表1所列。并对其进行归一化处理,生成图3中的特征数值表。特征数值表包含了每类干扰在各个浅层特征上的数值大小。我们将表中的每个单元格都视为一条记录,使用每个单元格对应的行表头r.jamming(特征数值表中的黄色部分)、列表头r.characteristics(特征数值表中的紫色部分)和数值r.value(特征数值表中的绿色部分)组成记录的内容。接着,通过图3中的特征嵌入机制,将每条记录的嵌入向量编码成一个记录向量 $r_{i,j}^{emb}$:

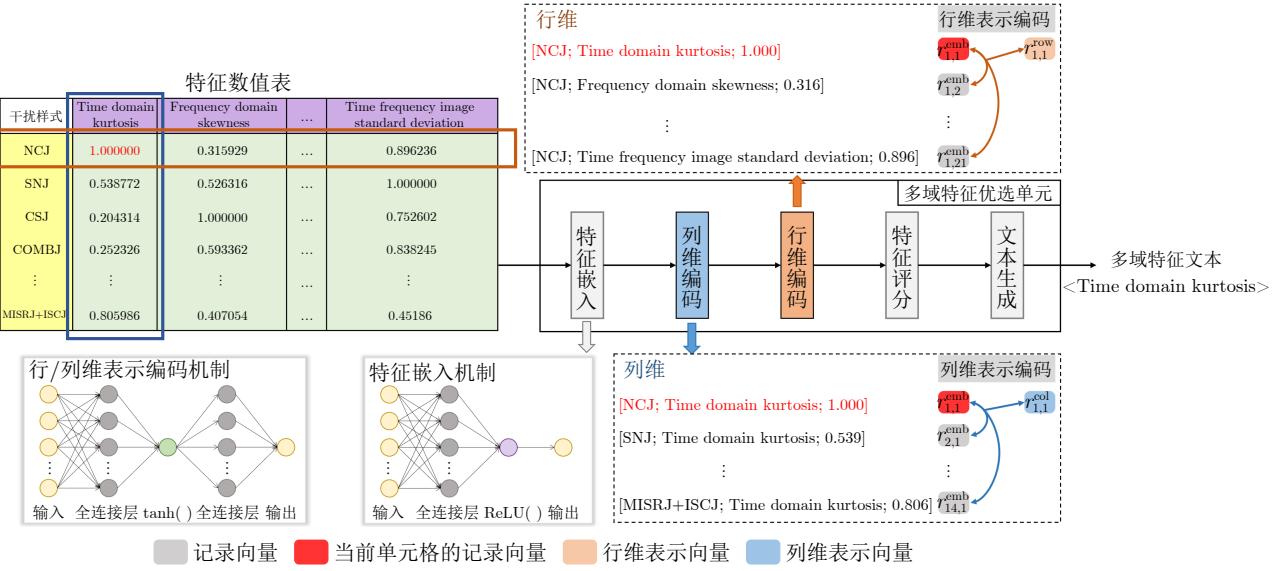


图3 多域特征优选单元算法流程示意图(以NCJ为例)

Fig. 3 Algorithm flowchart of the multidomain characteristics selection unit (taking NCJ as an example)

$$r_{i,j}^{\text{emb}} = \text{ReLU}(\mathbf{W}^e[r_{i,j}.jamming; r_{i,j}.characteristics; r_{i,j}.value] + \mathbf{b}^e) \quad (4)$$

其中, i, j 表示特征数值表的第 i 行第 j 列, $[;]$ 表示向量拼接, \mathbf{W}^e 和 \mathbf{b}^e 是全连接层的权重。

其次, 为了精确捕获记录之间数值的相对大小关系, 采用图3中的行\列表示编码机制, 关注同一列的其他记录, 引入其包含的上下文信息, 对当前记录进行列维编码, 进而获得列维表示向量 $r_{i,j}^{\text{col}}$:

$$\alpha_{i,j,i'}^{\text{col}} \propto \exp(\mathbf{W}_2^{\text{col}} \tanh(\mathbf{W}_1^{\text{col}}[r_{i,j}^{\text{emb}}; r_{i',j}^{\text{emb}}])) \quad (5)$$

$$\tilde{r}_{i,j}^{\text{col}} = \sum_{i'=1, i' \neq i}^R \alpha_{i,j,i'}^{\text{col}} r_{i',j}^{\text{emb}} \quad (6)$$

$$r_{i,j}^{\text{col}} = \mathbf{W}_3^{\text{col}} [\tilde{r}_{i,j}^{\text{col}}; r_{i,j}^{\text{emb}}] \quad (7)$$

其中, $\mathbf{W}_1^{\text{col}}$, $\mathbf{W}_2^{\text{col}}$ 和 $\mathbf{W}_3^{\text{col}}$ 是全连接层的权重, R 表示特征数值表的行数(不含表头)。按照上述同样的步骤, 对当前记录进行行维编码, 进而获得行维表示向量 $r_{i,j}^{\text{row}}$ 。

然后, 为了在评分特征时同时考虑不同维度记录的上下文信息, 获得当前记录的整体信息, 我们将当前记录的列、行表示向量连接, 并利用图3中的特征嵌入机制获得其全局表示向量 $r_{i,j}^{\text{gen}}$:

$$r_{i,j}^{\text{gen}} = \text{ReLU}(\mathbf{W}^s[r_{i,j}^{\text{col}}; r_{i,j}^{\text{row}}] + \mathbf{b}^s) \quad (8)$$

再通过列维表示向量 $r_{i,j}^{\text{col}}$ 与全局表示向量 $r_{i,j}^{\text{gen}}$ 可以计算出当前记录的列维分数 $\text{score}_{i,j}^{\text{col}}$:

$$\text{score}_{i,j}^{\text{col}} \propto \exp(\mathbf{W}_2^s \tanh(\mathbf{W}_1^s[r_{i,j}^{\text{gen}}; r_{i,j}^{\text{col}}])) \quad (9)$$

其中, \mathbf{W}_1^s 和 \mathbf{W}_2^s 是全连接层的权重。同样地, 通过行维表示向量 $r_{i,j}^{\text{row}}$ 与全局表示向量 $r_{i,j}^{\text{gen}}$ 可以计算

出当前记录的行维分数 $\text{score}_{i,j}^{\text{row}}$ 。接着, 计算全局特征分数 $\text{score}_{i,j}^{\text{gen}}$, 以量化该特征对于区分该类干扰的有效性和贡献度:

$$\text{score}_{i,j}^{\text{gen}} = \text{score}_{i,j}^{\text{col}} r_{i,j}^{\text{col}} + \text{score}_{i,j}^{\text{row}} r_{i,j}^{\text{row}} \quad (10)$$

最后, 将全局特征分数 $\text{score}_{i,j}^{\text{gen}}$ 与特征数值 $r_{i,j}.value$ 对应相乘, 以其结果每行最大值所对应的列表头 $r.characteristics$ 作为当前记录对应干扰的文本模态信息(特征名称的英文形式), 如<Time domain kurtosis>, 并输入文本编码器进行下一步的处理。

上述多域特征优选单元选择策略基于特征对干扰类型区分的贡献度进行筛选, 充分提取了当前单元格的上下文信息, 以确保最终优选特征的有效性和代表性。通过多域特征优选单元的处理, 不仅能够有效内嵌专家知识, 提高模型的适应性和可扩展性, 而且输出的文本描述简洁易懂, 便于后续处理和解释。

本文采用了与文献[28]中相似的Transformer网络结构作为文本编码器, 并加载了CLIP (Contrastive Language-Image Pre-training)^[22]文本编码器的预训练权重。该权重在大规模数据集DataComp-1B上训练得到, 通过加载该预训练权重, 使得我们的文本编码器在极端小样本情况下有效地将多域特征文本转换为更加具有判别力的文本特征, 并且保持良好的泛化能力。同时, 考虑到训练成本和识别精度之间的平衡, 我们选择直接冻结编码器的权重, 以降低训练过程中的时间和空间成本。在文本处理过程中, 我们首先应用了Tokenize函数对多域特征优选单元生成的文本<特征名称>, 即优选特征的英文名称, 进行编码, 将其转换为文本张量表示。

随后，这些张量被输入到Transformer网络中，以提取文本特征并实现多域浅层特征的嵌入。其中，Transformer网络由128个注意力单元组成，每个单元通过8个注意力头并行处理数据，最终输出的文本特征维度为128。输出文本特征在后续的对齐过程中充当锚点，并引导时频图像深层特征的调整和优化，从而增强模型对干扰类型的识别能力和泛化性。

3.3 多模态特征对齐

提取文本和图像模态特征后，有效联合这两种模态特征对于精确识别干扰至关重要。为此，本文构建了一个多模态特征对齐模块，如图2所示，以融合两种模态特征，使模型能够更充分地利用多域浅层特征和时频图像信息。由于文本特征来源于多域浅层特征，它们在不同干扰类型间展现出显著的类间差异。因此，多模态特征对齐模块主要利用多域文本特征的引导作用，对时频图像特征进行细致调整和优化。特别是在训练样本极为有限的情况下，文本特征对于确保时频图像特征的表征准确性至关重要。这使得调整后的时频图像特征在类内更聚集，在类间更分离，显著提高了干扰识别的精确度。此外，本文的深浅特征的联合方法，相比于直

$$L_{\text{aligned}} = - \sum_{i=0}^N \frac{1}{M} \left(\sum_{p \in P_p(i)} \ln \left[\frac{\exp(\mathbf{t}_i^T \mathbf{p}_p^+ / \tau)}{\sum_{a \in A_p(i)} \exp(\mathbf{t}_i^T \mathbf{p}_a^- / \tau)} \right] + \sum_{p \in P_t(i)} \ln \left[\frac{\exp(\mathbf{p}_i^T \mathbf{t}_p^+ / \tau)}{\sum_{a \in A_t(i)} \exp(\mathbf{p}_i^T \mathbf{t}_a^- / \tau)} \right] \right) \quad (11)$$

其中， \mathbf{p}_p^+ 和 \mathbf{p}_a^- 分别表示来自 $P_p(i)$ 和 $A_p(i)$ 的特征。同样地， \mathbf{t}_p^+ 和 \mathbf{t}_a^- 分别表示来自 $P_t(i)$ 和 $A_t(i)$ 的特征。 τ 为控制Softmax中对数范围的超参数。 M 为一个训练批次的样本量，且 $N = M - 1$ 。在式(11)中，将样本 x_i 的时频图像特征 \mathbf{p}_i 和多域文本特征 \mathbf{t}_i 分别与正样本和负样本的图像特征和文本特征进行对比。这种对比利用具有高度区分性的多域文本特征 \mathbf{t}_i 来引导时频图像特征 \mathbf{p}_i 越来越聚集于正样本 \mathbf{p}_p^+ ，同时与负样本 \mathbf{p}_a^- 越来越分离。通过最小化模态对齐损失 L_{aligned} ，时频图像特征的类内相似性和类间差异性显著增强，从而提高了整体模型的干扰识别性能。这一方法不仅联合了包含专家知识的多域浅层特征，而且将其有效地整合到时频图像特征的学习过程中，能够促进雷达干扰的多域浅层特征与深层网络特征之间的稳健联合，从而在极端小样本的情况下显著提升了干扰识别的效果。

在模型训练过程中，图像编码器和文本编码器同时进行优化。因此，模型的总训练损失 L_{total} 定义为

接融合多域浅层特征与深层特征，有助于解决因特征属性差异导致某些弱势特征作用减弱的问题。这能更充分地发挥两类特征的优势，有效利用它们的多样性和丰富性，提升干扰识别的性能。

在多模态对齐模块中，我们采用监督对比学习的方法，来实现时频图像特征与多域文本特征的对齐。首先，将提取的干扰时频图像特征 \mathbf{p}_i 和多域文本特征 \mathbf{t}_i 映射到模态对齐的高维空间中。然后，将映射后的多域文本特征作为锚点，通过监督对比学习策略调整时频图像特征，使得同一类型干扰的时频图像特征之间的距离逐渐缩短，从而使模型能够学习到更具鲁棒性和判别性的时频图像特征。监督对比学习策略通过最小化信息噪声对比估计(Information Noise Contrastive Estimation, InfoNCE)损失^[29]来实现。具体来说，对于任意样本 x_i ，通过图像编码器提取的时频图像特征定义为 \mathbf{p}_i 。根据样本 x_i 的标签确定相应的多域文本特征，并将其记为 \mathbf{t}_i 。在包含样本 x_i 的同一训练批次中，与 x_i 标签相同的样本称为正样本，不同标签的样本称为负样本。 $P_p(i)$ 和 $P_t(i)$ 分别表示正样本的图像特征集和文本特征集。相应地， $A_p(i)$ 和 $A_t(i)$ 分别表示负样本的图像特征集和文本特征集。因此，本文定义模态对齐损失 L_{aligned} 为

$$L_{\text{total}} = L_{\text{cls}} + \lambda \cdot L_{\text{aligned}} \quad (12)$$

其中， λ 是用于平衡模态对齐损失的超参数。在训练阶段，使用总损失值 L_{total} 通过反向传播算法计算梯度，并优化模型网络参数，从而提高干扰识别能力。在测试阶段，直接使用训练完成的图像编码器和分类头来预测干扰类型。

4 实验与分析

4.1 实验设置

为验证所提方法的有效性，我们利用2.1节构建的雷达有源干扰数据集进行了多种验证实验。该有源干扰数据集涵盖了丰富的干扰类型，包括8种经典单一干扰以及6种复合干扰，共计14种不同的干扰类型，确保了实验数据的代表性和多样性。表3详细列出了雷达发射信号及这14类干扰的主要参数设置。在本文实验中，设定了随机信噪比的范围为 $-5 \sim 5$ dB，并固定干信比为15 dB。对于每种干扰类型，本文随机生成了200个样本。除非特别说明，我们从每类干扰中随机选取了2个样本作为训练

表 3 雷达发射信号与干扰参数设置

Tab. 3 Parameter setting of target signal and jamming

		信号类型	参数	赋值
J_0	NCJ	LFM	时宽	10 μ s
			带宽	50 MHz
			采样频率	125 MHz
J_1	SNJ		干扰带宽	60 MHz
			高斯白噪声	$N(0, 1)$
			干扰个数	4~7个
J_2	CSJ		干扰时宽	1.5~2.5 μ s
			干扰占空比	0.8
			高斯白噪声	$N(0, 1)$
J_3	COMBJ		转发次数	2~4次
			切片时宽	2.5~5.0 μ s
			干扰占空比	0.9
J_4	SMSPJ		干扰时延	0.5 μ s
			干扰个数	9~17个
			干扰带宽	10~40 MHz
J_5	DFTJ		干扰个数	4~7个
			干扰时延	1~3 μ s
			假目标个数	5~10个
J_6	ISCJ		假目标时延	1~3 μ s
			转发次数	2~4次
			干扰个数	1~4个
J_7	MISRJ		切片时宽	1~3 μ s
			干扰时延	0.5~1.0 μ s
			转发次数	3~5次
J_8	NCJ+DFTJ		切片时宽	6~8 μ s
			干扰占空比	0.95
			干扰时延	0.5~1.0 μ s
J_9	SNJ+DFTJ			
J_{10}	CSJ+SMSPJ			由单一干扰参数决定
J_{11}	COMBJ+ISCJ			
J_{12}	MISRJ+SMSPJ			
J_{13}	MISRJ+ISCJ			

注: “ $N(0, 1)$ ”表示0为平均数、以1为标准差的正态分布。

集, 剩余的198个样本则构成测试集。测试集占总样本量的99%, 这一设置满足极端小样本条件(每类干扰训练样本为2~3个), 同时足以有效评估模型性能。

对于一维干扰信号, 我们通过STFT将其转换为对应的二维时频图像, 分辨率设定为256像素×256像素, 以便于后续的时频图像深层特征提取。对于采用EfficientNetV2网络的图像编码器, 我们先加载了使用大规模数据集ImageNet-1K预训练得

到的权重, 仅微调部分权重, 避免了在极端小样本条件下从头训练网络可能导致的过拟合问题。对于文本编码器, 我们直接采用了CLIP预训练模型的权重文件来初始化基于Transformer的文本编码器。鉴于CLIP的强大泛化能力和特征提取能力, 同时考虑到识别性能与训练效率之间的平衡, 我们决定冻结文本编码器, 不进行微调。在模型训练阶段, 我们选用了随机梯度下降优化器, 并设置了200次迭代, 初始学习率设定为0.004。所有干扰数据的仿真均在MATLAB 2021b环境中完成, 深度学习模型则在基于Python 3.8.18和Pytorch 1.11.0环境下实现。实验平台处理器为Intel(R) Core(TM) i7-12700F CPU, 主频为2.10 GHz; 图形处理器为NVIDIA GeForce RTX 4060。

为了广泛评估所提方法的干扰识别性能, 我们选用了总体平均识别准确率、召回率、F1指数、精准率和Kappa指数作为评估指标。在相同的实验条件下, 我们进行了50次蒙特卡罗实验, 并计算评价指标的平均值作为最终结果。此外, 我们还计算了每秒浮点运算次数与模型参数量、单次训练平均时间与单次测试平均时间来分别定量评估模型的空间和时间复杂度。

4.2 超参数调优

在网络总损失 L_{total} 中, 超参数 λ 负责平衡模态对齐损失 L_{aligned} 和时频图像分类损失 L_{cls} 之间的权重。同时, 在模态对齐损失 L_{aligned} 中, 超参数 τ 负责控制Softmax函数中的对数范围。 τ 的大小会影响模型对其预测结果的自信度, 同时增加对与正样本难以区分的负样本的关注度。这两个超参数对所提方法的识别性能产生重要影响。为了确定最优超参数值, 我们设计对比实验来进行评估。

首先, 本文中超参数 λ 的可调取值范围在0~1, 本文以0.2为间隔, 通过记录不同 λ 下所提方法的识别准确率变化来确定最优值。实验结果如表4所示, λ 的取值不同对识别性能产生较大影响。总

表 4 不同超参数 λ 对本文提出方法的识别准确率的影响(%)Tab. 4 The impact of different hyperparameters λ on the recognition accuracy of the proposed method (%)

超参数 λ 取值	准确率
0.2	85.17
0.4	88.79
0.6	91.80
0.8	93.55
1.0	<u>93.09</u>

注: 表中使用粗体标出了当前实验中最优的结果, 下划线标出了当前实验中次优的结果。

体来说, λ 值越大, 识别准确率逐步提高。当 λ 取值0.8时, 所提方法获得了最高的干扰识别准确率。因此, 我们将 λ 的值固定为0.8用于后续实验。

其次, 超参数 τ 的可调范围一般定义在0~2^[30], 本文以0.25为间隔, 在表5记录了在不同 τ 下所提方法的识别准确率变化。从表5的结果可以看出, 模型识别准确率随着 τ 的增加, 先提升后下降。在 τ 为0.75时, 本文方法取得了最高的干扰识别准确率。因此, 后续实验将 τ 值固定为0.75。

4.3 多域浅层特征引导有效性分析

本文提出的方法之所以能够显著提升雷达有源干扰识别的性能, 关键在于有效地利用了多域浅层特征来指导时频图像特征的调整与优化。这一过程使得时频图像特征在同类样本中更加集中, 在不同类样本间则更加区分, 从而实现更精确的识别效

表5 不同超参数 τ 对本文提出方法的识别准确率的影响(%)

Tab. 5 The impact of different hyperparameters τ on the recognition accuracy of the proposed method (%)

超参数 τ 取值	准确率
0.25	60.26
0.50	85.17
0.75	93.55
1.00	<u>88.83</u>
1.25	88.13
1.50	73.11
1.75	70.44
2.00	65.60

注: 表中使用粗体标出了当前实验中最优的结果, 下划线标出了当前实验中次优的结果。

果。在此过程中, 多域浅层特征的引导作用通过文本模态特征得以实现, 这些文本特征由设计的多域浅层特征嵌入模块生成。在该模块中, 多域特征优选单元与文本编码器协同工作, 生成用于多模态特征对齐的文本特征, 实现多域浅层特征的有效引导。需要做说明的是, 多域浅层特征嵌入模块中的**多域特征优选单元与文本编码器并非独立工作**, 它们之间的协同作用是实现多域浅层特征引导的核心。因此, 验证多域浅层特征嵌入模块的有效性, 实质上就是在验证多域特征优选单元和引导策略的有效性。

图4直观展示了有无多域浅层特征引导时, 使用主成分分析对时频图像特征进行降维, 得到可视化分布结果, 以及干扰的原始时频特征图。如图4(a)所示, 原始时频特征图中各干扰类型的聚类簇不紧凑, 并出现明显混叠, 表明构建的干扰数据集在特征空间中的本身可分性较低。对比图4(b)和图4(c)可以看出, 经过多域浅层特征引导后, 各干扰类型的时频图像特征分布明显更紧凑, 更易区分。尤其是红色方框标记的MISRJ, MISRJ+ISCJ和MISRJ+SMSJP这3种干扰类型。图4(b)中, 在无多域浅层特征引导时, 它们的特征分布簇混叠严重。这主要是因为MISRJ+ISCJ和MISRJ+SMSJP这两类复合干扰均包含MISRJ, 未经引导的时频图像特征在区分这些相似干扰时效果不佳。然而, 图4(c)中, 这3类干扰的特征分布簇有效分离, 且簇内紧凑性显著提升。这一结果表明, 多域浅层特征引导策略优化了时频图像特征, 提高了特征的类内紧凑性和类间可分性, 从而增强了模型的干扰识别能力。

从浅层物理特征与深层网络特征的结合来看,

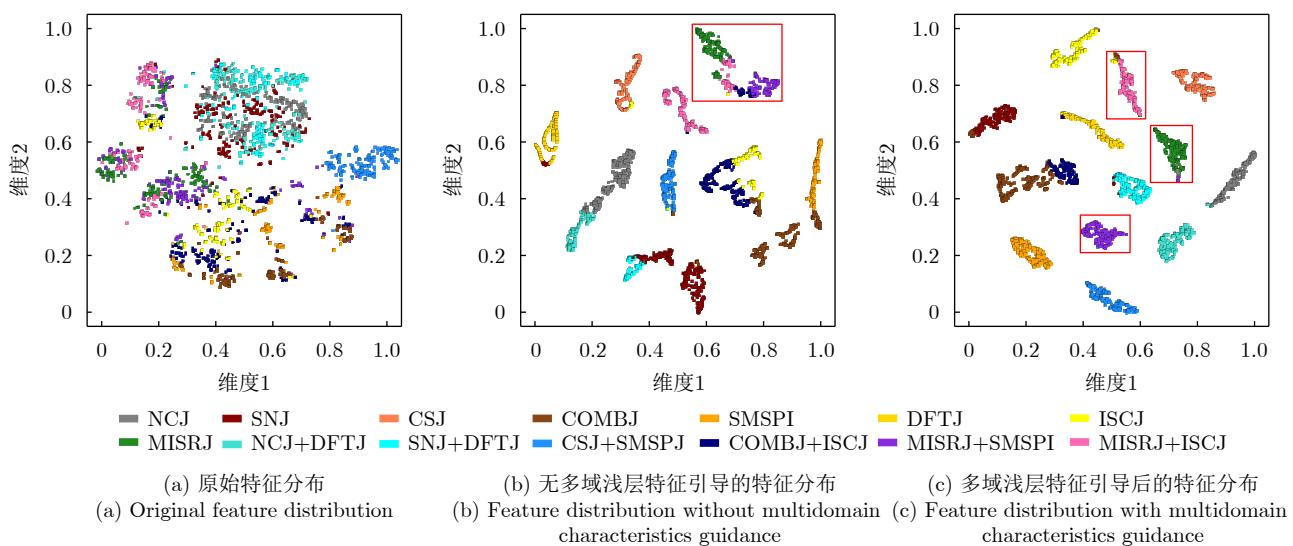


图4 时频图像深层特征的降维可视化分布图

Fig. 4 Visualization of time-frequency images deep features

多域浅层特征引导是一种隐式的浅深特征联合方式。与特征拼接、通道拼接或注意力机制等显式融合方法不同,本文提出的方法利用文本模态作为媒介,实现了浅层特征与深层特征的协同作用,从而达到了隐式特征联合的效果。为了全面评估多域浅层特征引导的有效性,我们比较了本文的隐式特征对比方法与显式的浅深特征联合方式。[表6](#)展示了对比实验的结果。本文比较了3种方法:只使用时频图像特征、采用深浅特征拼接(即特征串联),以及本文的深浅特征对比方法在干扰识别准确率上的表现。[表6](#)中,不包括表头的第一行模型被用作基线模型。通过比较[表6](#)中的结果,我们发现与基线模型相比,采用特征拼接这种显式联合方式的模型在识别性能上有所提高。然而,值得注意的是,特征拼接方式的性能并未超过本文采用的隐式特征对比方法。在训练效率方面,本文方法在单次训练时间上低于传统的特征拼接方法。这得益于多域特征优选单元对初始浅层特征的筛选,有效降低了数据处理的复杂度。这一结果进一步证实了多域浅层特征引导策略的有效性和先进性。通过对比学习,利用多域浅层特征嵌入模块处理得到的文本特征,模型能够学习到更具判别性的时频图像特征,显著提升了雷达干扰识别的性能。

4.4 干扰识别性能分析

为评估和验证本文提出的多域浅层特征引导下雷达有源干扰多模态对比识别模型的性能,本节将其与多种现有的代表性干扰识别模型进行比较。包括文献[9]中构建的用于干扰识别的支持向量机(Support Vector Machine, SVM)和2D-CNN、文献[17]提出的特征融合网络DFM (Deep Fusion Model)、文献[31]使用的元学习网络MAML (Model-Agnostic Meta-Learning)以及文献[10]提出的知识蒸馏网络JR-TFSAD (few-shot Jamming Recognition network via Time-Frequency Self-Attention and global knowledge Distillation)。其中,SVM和2D-CNN是经典的机器学习模型和深度学习架构。DFM是一种基于CNN的干扰特征融合识别方法。MAML和JR-TFSAD则代表了小样本学习领域中干扰识别方法的最新进展。

[表7](#)定量展示了在每类干扰仅有2个训练样本的条件下,不同识别方法的识别结果、时间复杂度和空间复杂度。其中,每类干扰的识别性能以准确率来衡量。从[表7](#)可以看出,尽管本文提出的方法在时间和空间复杂度上处于中等水平,但在识别性能上明显优于其他方法,平均准确率达到93.55%,比其他方法至少高出10%。这表明,通过多域浅层特征的引导,本文提出的方法在合理的计算资源消耗下,能够大幅增加干扰的识别准确率。对于SVM和2D-CNN这类依赖于大量训练样本的模型,在每类仅有两个训练样本的极端小样本条件下,模型参数优化受到限制,导致其识别效果不佳。此外,尽管DFM结合了浅层和深层特征,但其简单的显示特征融合方式所获得的识别特征判别力有限,导致其识别精度低于本文提出的方法。本文提出的方法利用多域浅层特征引导,通过文本特征与图像特征的对比联合,显著提高了识别特征的区分能力,从而在极端小样本条件下实现了识别性能的大幅提升。与MAML和JR-TFSAD等最新的小样本学习方法相比,本文方法的识别准确率至少高出10%,这充分证明了其在处理极端小样本干扰识别任务时的有效性和先进性。具体到每类干扰的识别准确率,本文方法均超过65%,而其他方法的识别准确率则显示出显著的不平衡,部分干扰类别的识别率甚至低于50%,最低可达20%左右。这些结果表明,本文方法在极端小样本条件下和复杂电磁对抗环境中具有高度鲁棒性,进一步凸显了其稳健性和优越性。

此外,[图5](#)展示了不同识别方法的混淆矩阵结果,以直观地证明本文方法的优越性。在混淆矩阵中,行轴表示干扰样本的**真实标签**,而列轴表示**预测标签**。混淆矩阵中的颜色深浅反映了元素值的大小,颜色越深表示值越大,颜色越浅则表示值越小。**主对角线上的值表示模型正确预测的样本数比例,即每类干扰的识别准确率;而非主对角线上的值则表示模型错误预测的样本比例。**[图5\(f\)](#)展示了所提方法的混淆矩阵,其色彩分布较为简单,主对角线上的颜色较深,表明识别准确率高;而非主对角线上的颜色较浅,几乎无色,表明误判率低。相比之下,其他对比方法的混淆矩阵色彩分布更为复

表 6 有效性验证实验结果
Tab. 6 Validity verification experiment results

多域浅层特征	时频图像深层特征	特征联合方式	准确率(%)	单次训练时间(s)
×	√	无	80.11	0.203
√	√	特征拼接	<u>85.63</u>	0.470
√	√	特征对比(本文方法)	93.55	<u>0.317</u>

注:“×”表示未使用相应的特征,“√”表示使用了相应的特征,并使用粗体标出了最优的结果,下划线标出了次优的结果。

表7 不同方法的识别性能对比结果(均值±标准差)

Tab. 7 Experimental results of jamming recognition performance evaluation between the proposed method and the comparative methods (mean ± standard deviation)

干扰类别和性能评价指标	干扰识别方法(%)					
	SVM	2D-CNN	DFM	MAML	JR-TFSAD	本文方法
干扰类别	NCJ	61.57±8.97	97.74±0.34	100.00±0.00	98.33±0.15	<u>98.97±0.00</u>
	SNJ	94.55±6.74	82.97±1.50	71.23±0.15	73.67±0.36	<u>89.23±0.15</u>
	CSJ	<u>96.16±6.02</u>	100.00±0.00	100.00±0.00	100.00±0.00	100.00±0.00
	COMBJ	<u>89.44±4.67</u>	37.95±0.00	48.21±0.27	68.99±0.56	31.79±0.73
	SMSPJ	<u>91.67±9.64</u>	90.15±4.86	100.00±0.00	85.67±0.39	73.33±0.00
	DFTJ	48.23±7.81	45.13±0.00	65.85±0.25	<u>94.98±0.19</u>	100.00±0.00
	ISCJ	77.22±7.11	37.44±0.00	60.00±0.13	92.00±0.20	<u>92.31±0.24</u>
	MISRJ	39.29±4.13	99.03±0.15	78.97±0.11	80.67±0.50	<u>92.31±0.00</u>
	NCJ+DFTJ	62.12±9.82	100.00±0.00	<u>95.90±0.05</u>	100.00±0.00	80.00±0.00
	SNJ+DFTJ	91.97±8.29	100.00±0.00	84.77±0.83	<u>99.67±0.23</u>	97.95±0.00
	CSJ+SMSPJ	64.39±8.36	68.21±0.00	41.54±0.98	75.33±0.20	<u>88.21±0.25</u>
	COMBJ+ISCJ	56.21±9.95	100.00±0.00	58.15±0.25	54.02±0.47	<u>77.95±0.00</u>
	MISRJ+SMSPJ	40.96±8.05	57.03±1.60	36.56±0.33	49.00±0.48	<u>77.44±0.25</u>
	MISRJ+ISCJ	63.38±8.84	23.59±6.62	97.95±0.13	<u>93.33±0.17</u>	71.28±0.26
识别结果	准确率(%)	69.80±1.42	73.41±0.42	74.23±0.26	83.26±0.45	<u>83.55±0.22</u>
	召回率(%)	69.97±1.57	73.74±0.34	74.64±0.22	83.35±0.39	<u>83.64±0.23</u>
	F1(%)	68.23±1.74	72.75±0.39	73.15±0.15	<u>83.59±0.56</u>	82.98±0.22
	精准率(%)	70.36±1.43	71.14±0.29	76.01±0.25	<u>86.79±0.36</u>	84.05±0.21
	Kappa(×100)	67.47±1.45	72.25±0.45	72.24±0.37	82.07±0.39	<u>82.29±0.22</u>
模型 复杂度	浮点运算次(10^9)	—	<u>1.456</u>	2.816	0.273	11.978
	模型参数量(10^6)	—	<u>15.471</u>	18.862	1.076	18.370
	单次训练平均时间(s)	—	<u>0.197</u>	0.270	0.127	51.200
	单次测试平均时间(s)	—	13.738	18.798	2.100	12.029

注: 每类干扰训练样本量为2; 表中使用粗体标出了最优的结果, 下划线标出了次优的结果。

杂, 主对角线上的颜色深浅不一, 非对角线上的颜色也较深, 这表明识别准确率较低。图5的可视化结果表明, 所提方法在整体识别性能上表现优异, 能够准确识别大多数干扰样本, 这进一步证明了其在极端小样本干扰识别任务中的卓越性和稳健性。

4.5 小样本性能分析

本文提出的识别方法采用了多域浅层特征引导策略, 旨在获得更具判别力和区分性的时频图像识别特征, 进而在极端小样本条件下实现更优秀的识别性能。为了评估本文方法在样本量极端有限情况下的识别优势, 本节探讨了不同训练样本量对识别性能的影响, 并进行了比较分析。

表8展示了在每类训练样本量为2~5时, 各方法的平均识别准确率。同时, 图6直观地展示了表8中数据的变化趋势。综合表8和图6进行分析, 可以明显看到随着每类训练样本量的增加, 所有方法的

识别性能均有所提升。但无论样本量如何变化, 本文提出的方法始终展现出最高的识别准确率, 这充分证明了其在识别性能上的优势。对于SVM, 2D-CNN和DFM这类通常需要较多训练样本的方法, 在训练样本量减少时, 它们的识别准确率显著下降, 并且均低于小样本识别模型。相比之下, MAML, JR-TFSAD和本文方法均属于小样本识别方法。尽管样本量减少会导致识别准确率下降, 但这种下降趋势比SVM, 2D-CNN和DFM较为缓慢。特别是, 在样本量减少时, 本文提出的方法的识别准确率下降最为缓慢。在样本量低于4的条件下, 其相较于MAML和JR-TFSAD, 本文方法的干扰识别性能优势尤为明显。以上结果证实了本文提出的方法在极端小样本条件下具有优越的干扰识别性能。

5 结语

为在极端小样本条件下实现高干扰识别准确

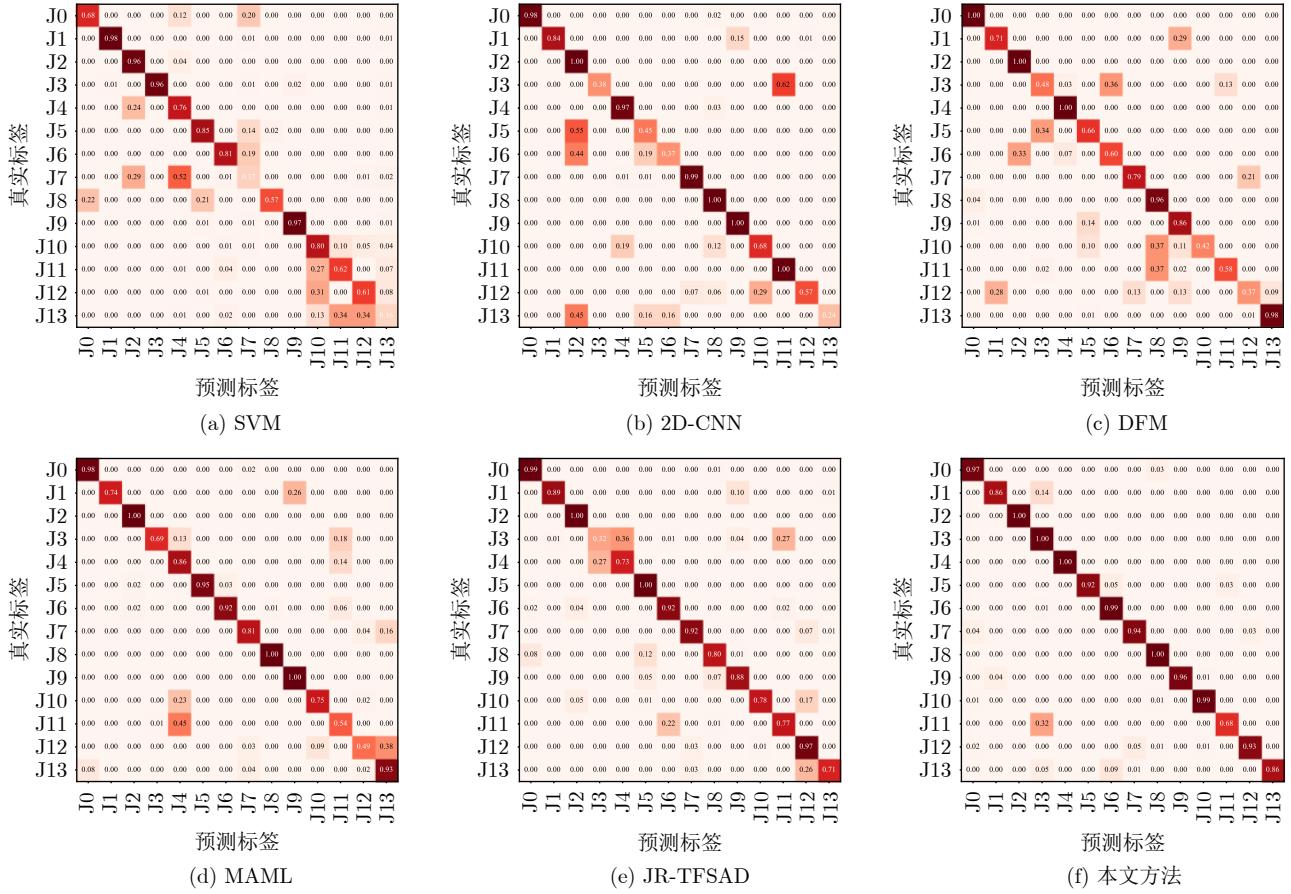


图 5 本文方法和对比方法的混淆矩阵实验结果

Fig. 5 Confusion matrix experimental results between the proposed method and the comparative methods

表 8 不同方法在不同训练样本下的平均识别准确率±标准差比较(%)

Tab. 8 Comparison of mean recognition accuracy ± standard deviation of different methods under different numbers of training samples (%)

干扰识别方法	每类干扰训练样本量			
	2个(占1%)	3个	4个	5个
SVM	69.80±1.42	75.63±0.96	80.95±0.36	82.78±0.46
2D-CNN	73.41±0.42	83.33±0.31	89.13±0.03	93.32±0.12
DFM	74.23±0.06	81.12±0.47	90.03±0.56	95.02±0.28
MAML	83.26±0.42	<u>90.67±0.35</u>	<u>95.43±0.21</u>	97.85±0.26
JR-TFSAD	<u>83.55±0.12</u>	88.70±0.30	93.40±0.29	<u>98.91±0.41</u>
本文方法	93.55±0.29	97.68±0.16	99.62±0.03	100.00±0.00

注: 表中使用粗体标出了最优的结果, 下划线标出了次优的结果。

率, 本文提出了一种基于多域浅层特征引导的雷达有源干扰多模态对比识别方法。该方法利用设计的多域浅层特征嵌入模块将浅层特征转换为文本模态特征。并通过多模态对比学习对时频图像特征进行调整优化, 实现更具判别力的识别特征学习, 确保在极端小样本情况下的高精准干扰识别性能。在构建的雷达有源干扰数据集上的实验结果显示, 通过

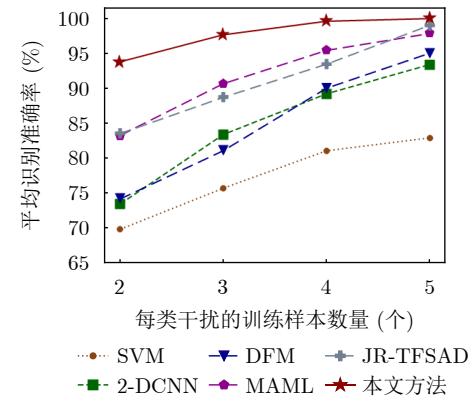


图 6 不同方法在不同训练样本下的识别准确率折线图

Fig. 6 Recognition accuracy line chart of different methods under different numbers of training samples

多域浅层特征引导, 本文方法的干扰识别平均准确率提升了13%以上, 验证了该引导策略的有效性。此外, 与当前主流干扰识别方法相比, 本文方法在2~5个训练样本量的设置下均展现出最高的干扰识别准确率, 进一步证明了其先进性和优越性。

利益冲突 所有作者均声明不存在利益冲突

Conflict of Interests The authors declare that there is no conflict of interests

参考文献

- [1] 崔国龙, 余显祥, 魏文强, 等. 认知智能雷达抗干扰技术综述与展望[J]. 雷达学报, 2022, 11(6): 974–1002. doi: [10.12000/JR22191](https://doi.org/10.12000/JR22191).
- CUI Guolong, YU Xianxiang, WEI Wenqiang, et al. An overview of antijamming methods and future works on cognitive intelligent radar[J]. *Journal of Radars*, 2022, 11(6): 974–1002. doi: [10.12000/JR22191](https://doi.org/10.12000/JR22191).
- [2] 解烽, 刘环宇, 胡锡坤, 等. 基于复数域深度强化学习的多干扰场景雷达抗干扰方法[J]. 雷达学报, 2023, 12(6): 1290–1304. doi: [10.12000/JR23139](https://doi.org/10.12000/JR23139).
- XIE Feng, LIU Huanyu, HU Xikun, et al. A radar anti-jamming method under multi-jamming scenarios based on deep reinforcement learning in complex domains[J]. *Journal of Radars*, 2023, 12(6): 1290–1304. doi: [10.12000/JR23139](https://doi.org/10.12000/JR23139).
- [3] 周红平, 王子伟, 郭忠义. 雷达有源干扰识别算法综述[J]. 数据采集与处理, 2022, 37(1): 1–20. doi: [10.16337/j.1004-9037.2022.01.001](https://doi.org/10.16337/j.1004-9037.2022.01.001).
- ZHOU Hongping, WANG Ziwei, and GUO Zhongyi. Overview on recognition algorithms of radar active jamming[J]. *Journal of Data Acquisition and Processing*, 2022, 37(1): 1–20. doi: [10.16337/j.1004-9037.2022.01.001](https://doi.org/10.16337/j.1004-9037.2022.01.001).
- [4] LV Qinzhe, FAN Hanxin, LIU Junliang, et al. Multilabel deep learning-based lightweight radar compound jamming recognition method[J]. *IEEE Transactions on Instrumentation and Measurement*, 2024, 73: 2521115. doi: [10.1109/TIM.2024.3400337](https://doi.org/10.1109/TIM.2024.3400337).
- [5] CAO Ru, CAO Jiuwen, MEI Jianping, et al. Radar emitter identification with bispectrum and hierarchical extreme learning machine[J]. *Multimedia Tools and Applications*, 2019, 78(20): 28953–28970. doi: [10.1007/s11042-018-6134-y](https://doi.org/10.1007/s11042-018-6134-y).
- [6] QU Qizhe, WANG Yongliang, LIU Weijian, et al. IRNet: Interference recognition networks for automotive radars via autocorrelation features[J]. *IEEE Transactions on Microwave Theory and Techniques*, 2022, 70(5): 2762–2774. doi: [10.1109/TMTT.2022.3151635](https://doi.org/10.1109/TMTT.2022.3151635).
- [7] WU Zhenhua, QIAN Jun, ZHANG Man, et al. High-confidence sample augmentation based on label-guided denoising diffusion probabilistic model for active deception jamming recognition[J]. *IEEE Geoscience and Remote Sensing Letters*, 2023, 20: 3508305. doi: [10.1109/LGRS.2023.3316282](https://doi.org/10.1109/LGRS.2023.3316282).
- [8] ZOU Wenxu, XIE Kai, and LIN Jinjian. Light-weight deep learning method for active jamming recognition based on improved MobileViT[J]. *IET Radar, Sonar & Navigation*, 2023, 17(8): 1299–1311. doi: [10.1049/rsn2.12420](https://doi.org/10.1049/rsn2.12420).
- [9] LV Qinzhe, QUAN Yinghui, FENG Wei, et al. Radar deception jamming recognition based on weighted ensemble CNN with transfer learning[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2022, 60: 5107511. doi: [10.1109/TGRS.2021.3129645](https://doi.org/10.1109/TGRS.2021.3129645).
- [10] LUO Zhenyu, CAO Yunhe, YEO T S, et al. Few-shot radar jamming recognition network via time-frequency self-attention and global knowledge distillation[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2023, 61: 5105612. doi: [10.1109/TGRS.2023.3280322](https://doi.org/10.1109/TGRS.2023.3280322).
- [11] KONG Yukai, XIA Senlin, DONG Luxin, et al. Compound jamming recognition via contrastive learning for distributed MIMO radars[J]. *IEEE Transactions on Vehicular Technology*, 2024, 73(6): 7892–7907. doi: [10.1109/TVT.2024.3358906](https://doi.org/10.1109/TVT.2024.3358906).
- [12] KONG Yukai, WANG Xiang, WU Changxin, et al. Active deception jamming recognition in the presence of extended target[J]. *IEEE Geoscience and Remote Sensing Letters*, 2022, 19: 4024905. doi: [10.1109/LGRS.2022.3184997](https://doi.org/10.1109/LGRS.2022.3184997).
- [13] ZHOU Hongping, WANG Lei, and GUO Zhongyi. Recognition of radar compound jamming based on convolutional neural network[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2023, 59(6): 7380–7394. doi: [10.1109/TAES.2023.3288080](https://doi.org/10.1109/TAES.2023.3288080).
- [14] PENG Ruihui, WEI Wenbin, SUN Dianxing, et al. Dense false target jamming recognition based on fast-slow time domain joint frequency response features[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2023, 59(6): 9142–9159. doi: [10.1109/TAES.2023.3316125](https://doi.org/10.1109/TAES.2023.3316125).
- [15] 魏赓力, 李凉海, 闫海鹏, 等. 基于多模特征融合的雷达干扰信号识别[J]. 遥测遥控, 2023, 44(4): 80–87. doi: [10.12347/j.ycyk.20230328001](https://doi.org/10.12347/j.ycyk.20230328001).
- WEI Gengli, LI Lianghai, YAN Haipeng, et al. Radar jamming signal identification based on multimode feature fusion[J]. *Journal of Telemetry, Tracking and Command*, 2023, 44(4): 80–87. doi: [10.12347/j.ycyk.20230328001](https://doi.org/10.12347/j.ycyk.20230328001).
- [16] 张顺生, 陈爽, 陈晓莹, 等. 面向小样本的多模态雷达有源欺骗干扰识别方法[J]. 雷达学报, 2023, 12(4): 882–891. doi: [10.12000/JR23104](https://doi.org/10.12000/JR23104).
- ZHANG Shunsheng, CHEN Shuang, CHEN Xiaoying, et al. Active deception jamming recognition method in multimodal radar based on small samples[J]. *Journal of Radars*, 2023, 12(4): 882–891. doi: [10.12000/JR23104](https://doi.org/10.12000/JR23104).
- [17] SHAO Guangqing, CHEN Yushi, and WEI Yinsheng. Deep fusion for radar jamming signal classification based on CNN[J]. *IEEE Access*, 2020, 8: 117236–117244. doi: [10.1109/ACCESS.2020.3004188](https://doi.org/10.1109/ACCESS.2020.3004188).
- [18] ZHANG Yipeng, LU Dongdong, QIU Xiaolan, et al. Scattering-point topology for few-shot ship classification in SAR images[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2023, 16:

- 10326–10343. doi: [10.1109/JSTARS2023.3328066](https://doi.org/10.1109/JSTARS2023.3328066).
- [19] GENG Jie, ZHANG Yuhang, and JIANG Wen. Polarimetric SAR image classification based on hierarchical scattering-spatial interaction transformer[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 5205014. doi: [10.1109/TGRS.2024.3362360](https://doi.org/10.1109/TGRS.2024.3362360).
- [20] 郭帅, 陈婷, 王鹏辉, 等. 基于角度引导Transformer融合网络的多站协同目标识别方法[J]. 雷达学报, 2023, 12(3): 516–528. doi: [10.12000/JR23014](https://doi.org/10.12000/JR23014).
- GUO Shuai, CHEN Ting, WANG Penghui, et al. Multistation cooperative radar target recognition based on an angle-guided Transformer fusion network[J]. *Journal of Radars*, 2023, 12(3): 516–528. doi: [10.12000/JR23014](https://doi.org/10.12000/JR23014).
- [21] CHEN Xiaolong, SU Ningyuan, HUANG Yong, et al. False-alarm-controllable radar detection for marine target based on multi features fusion via CNNs[J]. *IEEE Sensors Journal*, 2021, 21(7): 9099–9111. doi: [10.1109/JSEN.2021.3054744](https://doi.org/10.1109/JSEN.2021.3054744).
- [22] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]. The 38th International Conference on Machine Learning (ICML), 2021: 8748–8763.
- [23] 李宏, 郑光勇, 郭雷, 等. 雷达相参压制干扰信号分析[J]. 电子信息对抗技术, 2013, 28(3): 36–40. doi: [10.3969/j.issn.1674-2230.2013.03.009](https://doi.org/10.3969/j.issn.1674-2230.2013.03.009).
- LI Hong, ZHENG Guangyong, GUO Lei, et al. Jamming analysis of radar coherent suppressing[J]. *Electronic Information Warfare Technology*, 2013, 28(3): 36–40. doi: [10.3969/j.issn.1674-2230.2013.03.009](https://doi.org/10.3969/j.issn.1674-2230.2013.03.009).
- [24] WEI Shaopeng, ZHANG Lei, LU Jingyue, et al. Modulated-ISRI rejection using online dictionary learning for synthetic aperture radar imagery[J]. *Journal of Systems Engineering and Electronics*, 2024, 35(2): 316–329. doi: [10.23919/JSEE.2023.000076](https://doi.org/10.23919/JSEE.2023.000076).
- [25] TAN Mingxing and LE Q V. EfficientNetV2: Smaller models and faster training[C]. The 38th International Conference on Machine Learning (ICML), 2021: 10096–10106.
- [26] GONG Heng, FENG Xiaocheng, QIN Bing, et al. Table-to-text generation with effective hierarchical encoder on three dimensions (row, column and time)[C]. The 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, Hong Kong, China, 2019: 3143–3152. doi: [10.18653/v1/D19-1310](https://doi.org/10.18653/v1/D19-1310).
- [27] LI Liang, MA Can, YUE Yinliang, et al. Improving encoder by auxiliary supervision tasks for table-to-text generation[C]. The 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), 2021: 5979–5989. doi: [10.18653/v1/2021.acl-long.466](https://doi.org/10.18653/v1/2021.acl-long.466).
- [28] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners[J]. *OpenAI Blog*, 2019, 1(8): 9.
- [29] KHOSLA P, TETERWAK P, WANG Chen, et al. Supervised contrastive learning[C]. The 34th International Conference on Neural Information Processing Systems (NIPS'20), Vancouver, Canada, 2020: 1567.
- [30] WANG Feng and LIU Huaping. Understanding the behaviour of contrastive loss[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Nashville, USA, 2021: 2495–2504. doi: [10.1109/CVPR46437.2021.00252](https://doi.org/10.1109/CVPR46437.2021.00252).
- [31] LIU Mingqian, LIU Zilong, LU Weidang, et al. Distributed few-shot learning for intelligent recognition of communication jamming[J]. *IEEE Journal of Selected Topics in Signal Processing*, 2022, 16(3): 395–405. doi: [10.1109/JSTSP.2021.3137028](https://doi.org/10.1109/JSTSP.2021.3137028).

作者简介

郭文杰, 硕士生, 主要研究方向为雷达干扰信号智能识别。

吴振华, 博士, 副教授, 主要研究方向为雷达智能干扰对抗。

曹宜策, 博士, 讲师, 主要研究方向为雷达智能干扰对抗、遥感图像解译。

张 强, 博士, 研究员, 主要研究方向为天基信号处理。

张 磊, 博士, 教授, 主要研究方向为雷达信号处理。

杨利霞, 博士, 教授, 主要研究方向为电磁散射与逆散射、电波传播及天线理论与设计、计算电磁学等。

(责任编辑: 于青)